Msc Eduardo Verri
Dra Marise Miranda

Estudo de caso 2: Implementação de regressão linear com 2 ou mais variáveis numéricas

O termo "Regressão" surgiu em 1885 com o antropólogo, matemático e estatístico Francis Galton. A sua aplicabilidade surgiu como metodologia usada na Antropometria, ou seja, estudo das medidas e da matemática dos corpos humanos.

Lembre-se que temos no nosso material o modelo do estudo antropométrico quando estudamos o caso do IMC.

O estudo realizado por Galton, observou as estaturas de pais e seus filhos. O resultado da observação demostrou que os filhos de pais com estatura baixa em relação à média, têm tendência a serem mais altos que seus pais, e filhos de pais com estatura alta em relação à média tendem a ser mais baixos que seus pais, ou seja, as alturas dos seres humanos em geral tendem a **regredir** à média. Para realizar a demonstração, podemos derivar essas medidas, cada qual, pela diferença da média das medidas observadas.

Quando falamos em derivar, podemos ter ao longo do eixo x, as diferenças entre os pontos A e B, B e C, C e D, e assim por diante, traçando tangentes a cada curva (reta) desses trechos segmentados, pode resultar em retas tangentes aproximadas. Veja a figura abaixo, dado o conjunto, a sua derivada são as retas tangentes as cada segmento. Isto é uma derivada. No entanto, não precisamos derivar cada segmento para expressá-los como uma reta (curva). Podemos aproximar cada segmento de um único modelo, então isto quer dizer que podemos regredir todas essas retas lineares a uma única, que represente todas.

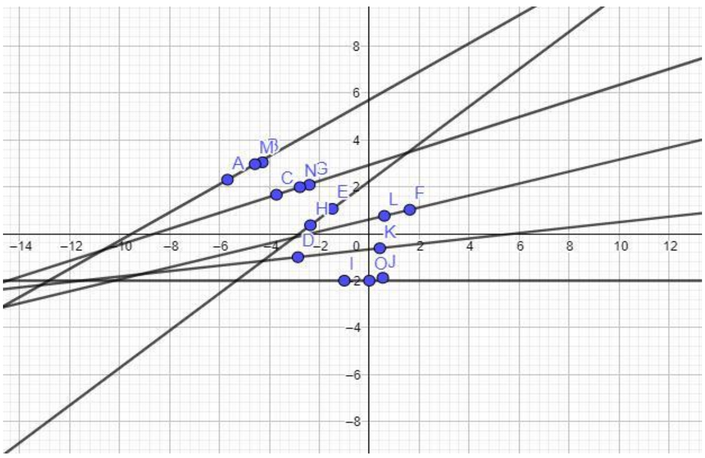

Hoje, conhecemos a análise de regressão como uma técnica que permite estimar o comportamento médio de uma variável resposta em relação a uma ou mais variáveis explicativas. Por exemplo, estimar a altura média dos filhos a partir da altura de seus pais; estimar a produção média de uma lavoura a partir da quantidade de chuva, quantidade de adubo, etc. E como uma delas influência a outra.

É **importante notar que, apesar de ser uma possibilidade, a análise de regressão não tem como objetivo obter estimativas pontuais de eventos futuros, mas sim de estimar médias condicionais e efeitos, relativos ao comportamento dos dados, apenas uma previsão, um forecast.** A Análise de Regressão é chamada de Simples, quando existe apenas uma variável resposta e uma variável explicativa, e Múltipla quando existe uma variável resposta e mais de uma explicativa. Casos em que existe mais de uma variável resposta são analisados pela regressão Multivariada.

Implementando um modelo de Regressão Linear Simples:

O modelo de regressão linear simples consiste de 2 parâmetros, que correspondem aos coeficientes de uma equação da reta qualquer:

$$\mathbf{Y=\alpha+\beta X}$$

Y é a esperança ou média da variável de resposta, você pode chamar de uma possível estimativa. O x é a variável que influência a variável de resposta, diretamente ou inversamente. Os coeficientes **α e β** são estimados através do Método dos Mínimos Quadrados.

Os mínimos quadrados são as variâncias de cada ponto, ou seja, é a diferença variável de cada ponto em relação a média, como cada ponto está equidistante diferentemente em relação a variância de outros pontos, cada um terá um erro distinto (erro mínimo quer dizer diferença). Cada variância pode ser positiva ou negativa, eleva-se ao quadrado para deixar em módulo. Regra dos mínimos quadrados. Quando se encontra estes mínimos pode-se traçar uma reta que os represente de uma forma estimada. O objetivo deste método é obter uma reta que minimiza as distâncias entre os valores estimados e os valores observados.

O **parâmetro α** representa o intercepto da reta, onde ela cruza o eixo **Y**, ou seja, o valor de **Y** para o qual **X = 0**. Este parâmetro só será interpretado na prática quando existir sentido real na variável explicativa assumindo valor zero.

Já o **parâmetro β** representa, neste caso, o efeito da variável explicativa sobre a variável resposta. O quanto ela pode influenciar o resultado Y.

A função que realiza o ajuste dessa reta ou modelo de regressão linear no R é a *lm()* na linguagem R. Neste exemplo, utilizaremos um conjunto de dados em que a variável resposta (Y) é o tempo de reação(curtida) da pessoa à uma certa notícia no Twiter, em segundos, e a variável explicativa

(X) é a idade do indivíduo. (Fonte: Bussab, 1988). No R, dados em tabelas são objetos do tipo *data frame*, nos quais cada coluna corresponde a uma variável e cada linha corresponde a uma observação.

```
>dados<-data.frame(tempo=c(96,92,106,100,98,104,110,101,116,106,109,100,112,105,118,108,113,112,
127,117),idade = c(20,20,20,20,25,25,25,25,30,30,30,30,35,35,35,35,40,40,40,40))

> dados
   tempo idade
1     96  20
2     92  20
3    106  20
4    100  20
5     98  25
6    104  25
7    110  25
8    101  25
9    116  30
10   106  30
11   109  30
12   100  30
13   112  35
14   105  35
15   118  35
16   108  35
17   113  40
```

Msc Eduardo Verri
Dra Marise Miranda

18 112   40
19 127   40
20 117   40

Precisamos da library ggplot

install.packages("devtools")
devtools::install_github("tidyverse/ggplot2")
Enter one or more numbers, or an empty line to skip updates:1 library(ggplot2)

> ggplot(dados, aes(x = idade, y = tempo))+ + geom_point()

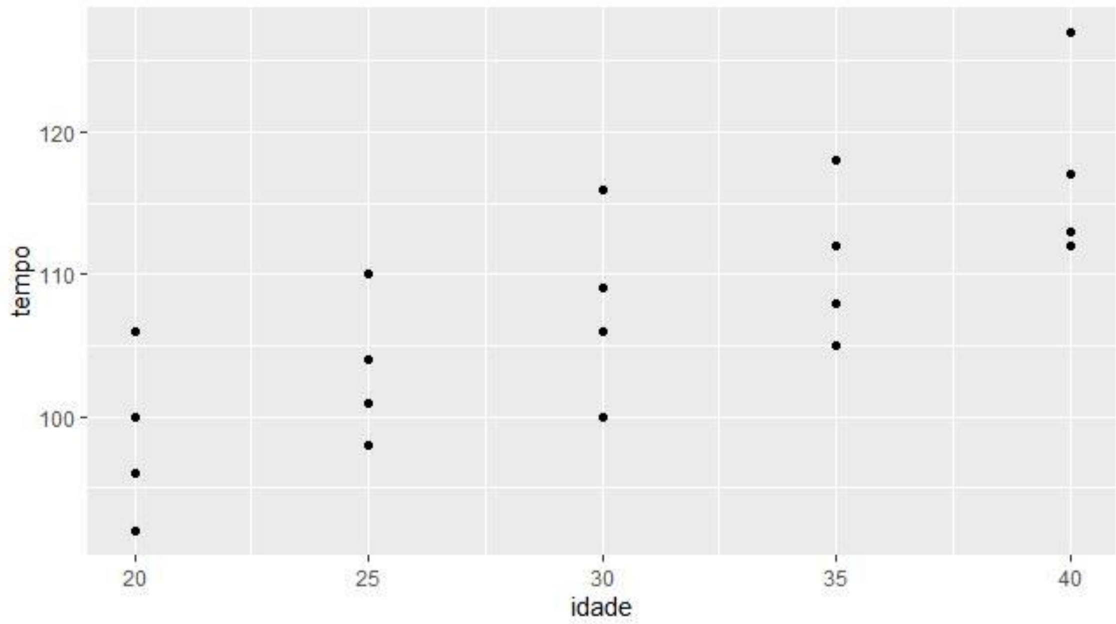

Observe o crescimento nos valores da variável tempo de acordo com o aumento das variáveis idade. Estima-se que haja um efeito da idade sobre o tempo de reação de curtidas diretamente. Coeficiente β > 0 é positivo.

Agora vamos ajustar o modelo para explicar este conjunto de dados.

Ajuste do Modelo:
> modelo <-lm(data = dados, formula = tempo ~idade)
> modelo$coefficients
(Intercept)   idade
        80.50.9
Podemos simplesmente consultar as estimativas dos parâmetros:

E temos a equação da reta ajustada:
Y = 80.5 + 0.9 ∗ Idade

Perceba que a equação ajusta os pontos para estimativas de cada um deles. Por este motivo, fazse necessário testar qual significância desses novos valores estimados. Isto quer dizer, qual grau de confiança ou confiabilidade podemos afirmar que o modelo é linear, se aproximando de zero.

Vamos usar o comando summary para o modelo. Este comando estatístico indicará se os parâmetros estimados são significantes, isto quer dizer, se são valores distintos de zero, tem valor, tem significado.

O summary no modelo linear também retorna a correlação entre essas duas variáveis, que é a medida R^2(adjusted R-squared). Este parâmetro indica o quanto da variação presente nos dados está sendo explicada pela covariável. Se há ou não uma correlação.

```
> summary(modelo)
```

```
Call:
lm(formula = tempo ~ idade, data = dados)

Residuals:
   Min  1Q   Median        3Q      Max
-7.500 -4.125 -0.750     2.625  10.500

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 80.5000     5.4510 14.768 1.67e-11
idade        0.9000     0.1769  5.089  7.66e-05

(Intercept) ***
idade       ***
---
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.593 on 18 degrees of freedom
Multiple R-squared: 0.5899,     Adjusted R-squared: 0.5672
F-statistic: 25.9 on 1 and 18 DF, p-value: 7.662e-05
```

O resultado do summary (modelo) revela que saídas estimadas relativas ao parâmetros, há um erro padrão associado a cada estimativa, uma estatística t e um p-valor associado, resultado do teste t utilizado para saber se as estimativas são realmente diferentes de zero. Quanto mais asteriscos presentes ao lado do efeito estimado, maior o nível de confiança com que podemos afirmar que o efeito não é nulo.

Quanto ao R^2, ao utilizar apenas uma variável é normal que o valor não seja extremamente alto. De qualquer maneira, na prática, 0.56 é um valor bastante razoável. De certa forma a idade afeta no tempo de curtidas.

Agora vamos qualificar o modelo linear.

Passando para a **qualidade do ajuste**

```
>ggplot(dados, aes(x = idade, y=tempo)) +
```

Msc Eduardo Verri
Dra Marise Miranda


```
+        geom_point()+
+        geom_smooth(method =lm, se = FALSE)
```

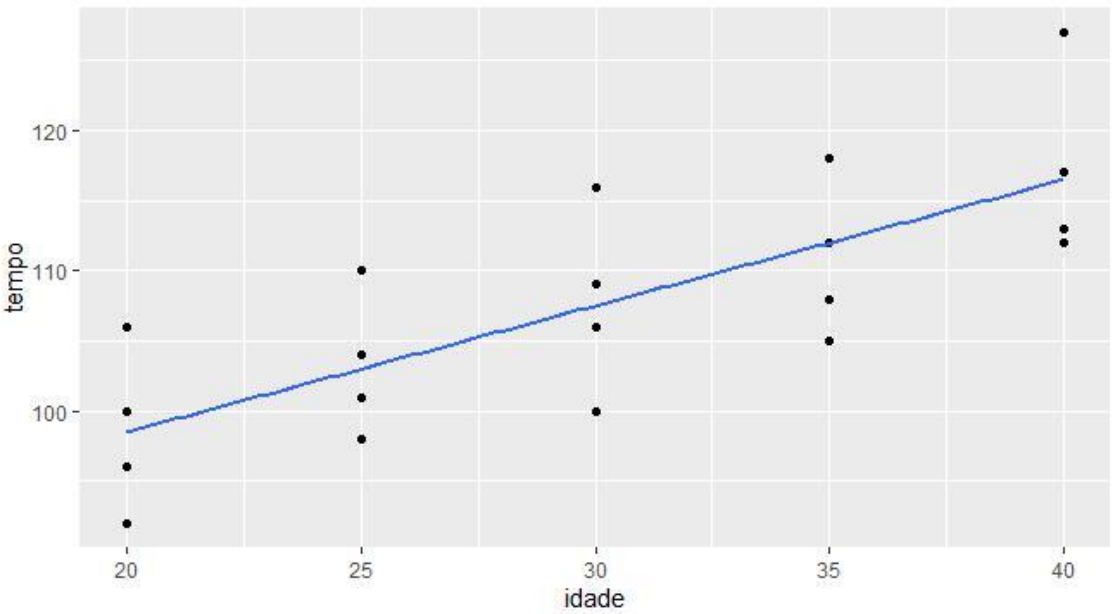

A reta estimada claramente não coincidirá com todos os nossos dados. As medidas de distância entre os dados observados e a reta estimada são chamadas ***resíduos***. Os resíduos são utilizados para avaliar o ajuste do modelo, e a qualidade das estimativas feitas a partir dele.

Mostrando os dados estimados:

```
> predict(modelo)
    1   2     3   4     5     6    7     8     9    10
  98.5 98.5 98.5 98.5 103.0 103.0 103.0 103.0 107.5 107.5
   11  12    13    14    15  16    17   18    19    20
107.5 107.5 112.0 112.0 112.0 112.0 116.5 116.5 116.5 116.5

> valor_aj<-predict(modelo)
> valor_aj
    1   2     3   4     5     6    7     8     9    10
  98.5 98.5 98.5 98.5 103.0 103.0 103.0 103.0 107.5 107.5
   11  12    13    14    15  16    17   18    19    20
107.5 107.5 112.0 112.0 112.0 112.0 116.5 116.5 116.5 116.5

> valor_aj<-data.frame(predict(modelo))
> valor_aj
  predict.modelo.
1         98.5
2         98.5
3         98.5
4         98.5
5        103.0
6        103.0
```

Msc Eduardo Verri
Dra Marise Miranda


```
7          103.0
8          103.0
9          107.5
10         107.5
11         107.5
12         107.5
13         112.0
14         112.0
15         112.0
16         112.0
17         116.5
18         116.5
19         116.5
20         116.5
```

```
> dados$id<-(c(1:20))
> dados
  tempo idade id
1    96 201
2    92 202
3   106  20 3
4   100  20 4
5    98 255
6   104  25 6
7   110  25 7
8   101  25 8
9   116  30 9
10  106  30 10
11  109  30 11
12  100  30 12
13  112  35 13
14  105  35 14
15  118  35 15
16  108  35 16
17  113  40 17
18  112  40 18
19  127  40 19
20  117  40 20
```

Vamos ordenar o id para que fique do lado esquerdo da tabela.

```
> library(dplyr)
> dados<-dados %>%
+       select(id,
tempo,idade) > dados
  id tempo
idade 119620
229220
3310620
```

```
44100       20
55     98   25
66104       25
77110       25
88101       25
99116       30
10 10  106   30
11 11  109   30
12 12  100   30
13 13  112   35
14 14  105   35
15 15  118   35
16 16  108   35
17 17  113   40
18 18  112   40
19 19  127   40
20 20  117   40
```

Vamos incluir o id na tabela valor_aj

```
> valor_aj$id<-(c(1:20))
> valor_aj
  predict.modelo. id
1          98.5 1
2          98.5 2
3          98.5 3
4          98.5 4
5         103.0 5
6         103.0 6
7         103.0 7
8         103.0 8
9         107.5 9
10         107.5 10
11         107.5 11
12         107.5 12
13         112.0 13
14         112.0 14
15         112.0 15
16         112.0 16
17         116.5 17
18         116.5 18
19         116.5 19
20         116.5 20
```

Vamos mudar a coluna de id para a primeira posição da tabela

```
> valor_aj<-valor_aj %>%
+       select(id,predict.modelo.)
> valor_aj
  id predict.modelo.
```

```
1  1    98.5
2  2    98.5
3  3    98.5
4  4    98.5
5  5   103.0
6  6   103.0
7  7   103.0
8  8   103.0
9  9   107.5
10 10  107.5
11 11  107.5
12 12  107.5
13 13  112.0
14 14  112.0
15 15  112.0
16 16  112.0
17 17  116.5
18 18  116.5
19 19  116.5
20 20  116.5
```

Vamos analisar como os valores ajustados se comportam. Estes valores são exatamente os valores recalculados a partir da equação ***Y = 80.5 + 0.9 ∗ Idade***

Vamos fazer um teste, recalcular os valores com a nova equação para validar o resultado obtido em cada ponto pelo comando predict:
Para isso faça:

```
> valor_aj$calculado<-80.5 +0.9*dados$idade
> valor_aj
   id predict.modelo. calculado
1  1    98.5     98.5
2  2    98.5     98.5
3  3    98.5     98.5
4  4    98.5     98.5
5  5   103.0    103.0
6  6   103.0    103.0
7  7   103.0    103.0
8  8   103.0    103.0
9  9   107.5    107.5
10 10  107.5    107.5
11 11  107.5    107.5
12 12  107.5    107.5
13 13  112.0    112.0
14 14  112.0    112.0
15 15  112.0    112.0
16 16  112.0    112.0
17 17  116.5    116.5
18 18  116.5    116.5
19 19  116.5    116.5
20 20  116.5    116.5
```

PARTE 4 – Análise Crédito - Modelagem

Veja que o resultado do valor na coluna predict.modelo. é exatamente o mesmo da coluna calculado pela fórmula do modelo linear.

Isto que dizer que os pontos estimados, seriam os melhores valores para um modelo linear.

> plot(valor_aj)

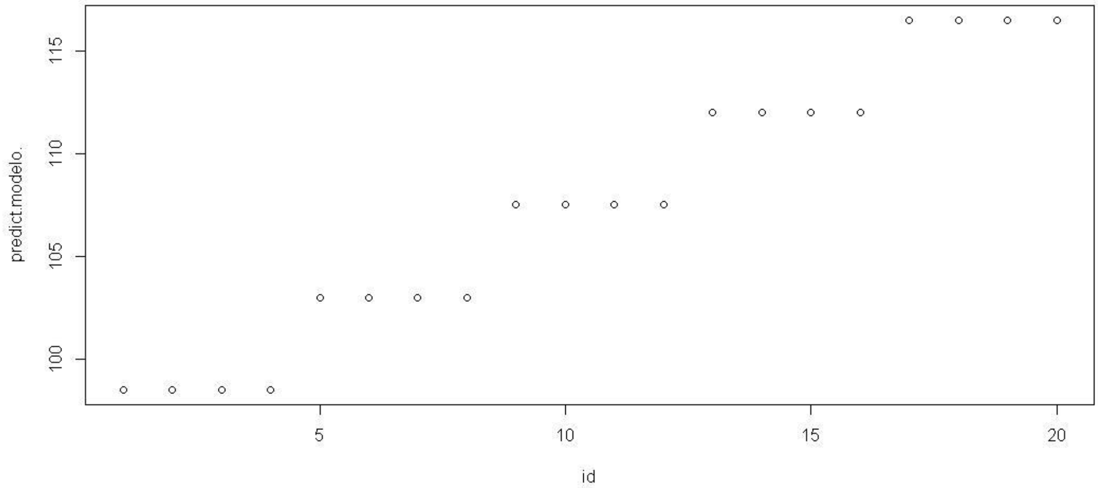

Vamos fazer um join entre as duas tabelas, criando um novo data set, com a idade e o novo valor estimado do modelo linear.

> dados1_model<-merge(dados,valor_aj)
> dados1_model

	id	tempo	idade	predict.modelo.	calculado
1	1	96	20	98.5	98.5
2	2	92	20	98.5	98.5
3	3	106	20	98.5	98.5
4	4	100	20	98.5	98.5
5	5	98	25	103.0	103.0
6	6	104	25	103.0	103.0
7	7	110	25	103.0	103.0
8	8	101	25	103.0	103.0
9	9	116	30	107.5	107.5
10	10	106	30	107.5	107.5
11	11	109	30	107.5	107.5
12	12	100	30	107.5	107.5
13	13	112	35	112.0	112.0
14	14	105	35	112.0	112.0
15	15	118	35	112.0	112.0
16	16	108	35	112.0	112.0
17	17	113	40	116.5	116.5
18	18	112	40	116.5	116.5
19	19	127	40	116.5	116.5
20	20	117	40	116.5	116.5

```
> ggplot(dados1_model,aes(x=idade,y=calculado))
+ + geom_point()+
+  geom_smooth(method = lm,se =FALSE)
```

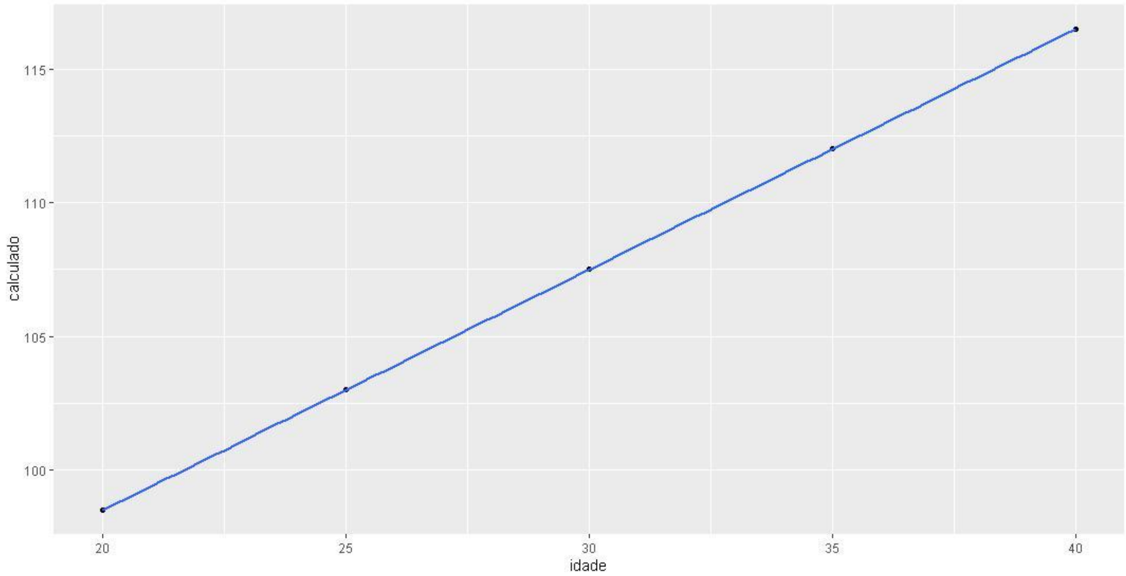

Observe o ajuste preciso do modelo.

Estes valores calculados seriam os valores previstos, estimados.

Condições para um Bom Ajuste de Modelo de Regressão Linear

Assim como qualquer método estatístico, a Regressão Linear, para ser corretamente utilizada, precisa que os dados estejam de acordo com algumas condições assumidas pelo modelo:

- **Normalidade dos Resíduos**

É necessário que os resíduos gerados pelo ajuste da reta sigam distribuição Normal.

- **Homocedasticidade**

É necessário que a variância de Y seja constante para todos os valores de X. Ideal, mas com pouca diferença. Variáncia é a diferença do valor em relação ao valor médio de todos os dados.

- **Independência**

É necessário que não exista estrutura de dependência entre os dados, para que os resíduos sejam independentes e identicamente distribuídos.

Análise Residual ou de erros:
Dadas as suposições anteriores, validadas por meio dos gráficos residuais.

```
> par(mfrow = c(2,2))
> plot(modelo, which=c(1:4),pch=20)
```

PARTE 4 – Análise Crédito - Modelagem

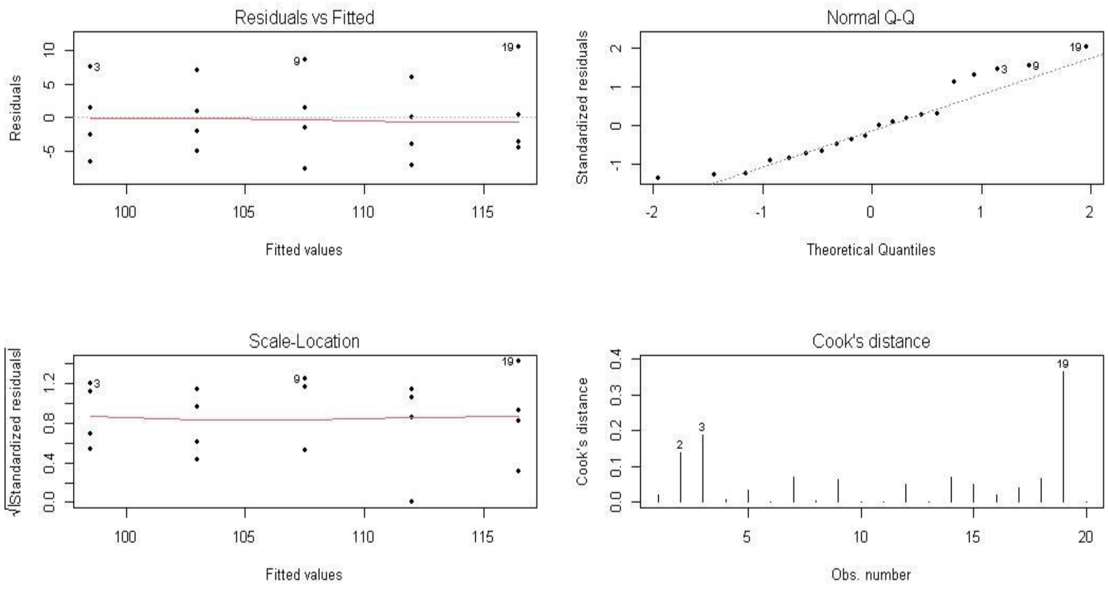

Residuals vs Fitted – residual vs ajustado. No primeiro gráfico, temos os resíduos em função dos valores estimados. Podemos utilizar este gráfico para observar a independência e a **homocedasticidade**, se os resíduos se distribuem de maneira razoavelmente aleatória e com mesma amplitude em **torno do zero**.

Normal quantil-quantil. No segundo gráfico, podemos **avaliar a normalidade dos resíduos**. A linha diagonal pontilhada **representa a distribuição normal teórica**, e os pontos a distribuição dos resíduos observados. Espera-se que não exista grande fuga dos pontos em relação à reta teórica.

Scale-location. O terceiro gráfico pode ser avaliado da mesma maneira que o primeiro, observando a aleatoriedade e amplitude, desta vez dos resíduos padronizados. Este **gráfico** mostra se os resíduos são distribuídos igualmente ao longo dos intervalos de preditores. È assim que pode-se verificar a suposição de variância igual (homocedasticidade).

E o último gráfico permite visualizar as **Distâncias de Cook** das observações, uma medida de influência quando pode indicar a presença de *outliers* que possuem valor maior do que 1. Os números relacionados a cada linha vertical são as quantidades de observações em torno daquele valor.

Quando a análise gráfica apresenta dúvidas, é possível também realizar testes estatísticos sobre os resíduos obtidos.

Msc Eduardo Verri
Dra Marise Miranda

Estudo de caso 2: Base de dados LoanData em UCI Machine Learning (Dados empréstimo)

A análise do risco de crédito e a tomada de decisão na concessão de crédito é uma das operações mais importantes para as instituições financeiras. Levando em consideração os resultados anteriores, precisamos treinar um modelo para prever com precisão os resultados futuros (fonte: AWS Model R)

Carregue as bibliotecas que vamos usar.

Use Tools Install Packages Cran

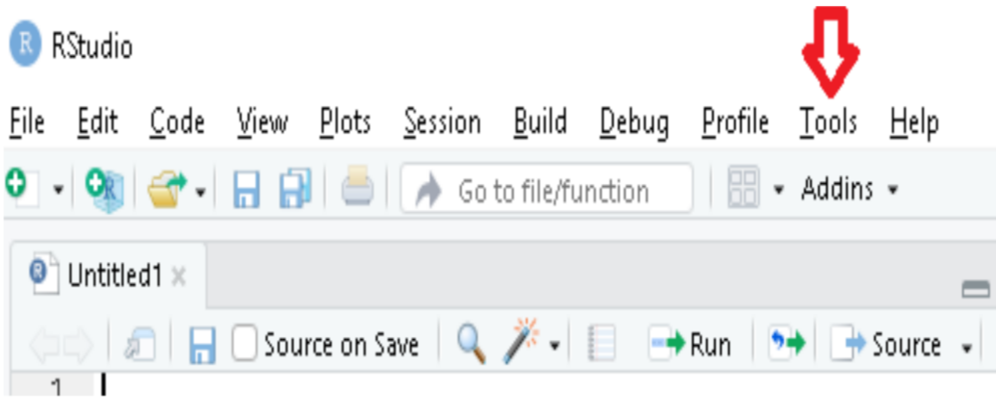

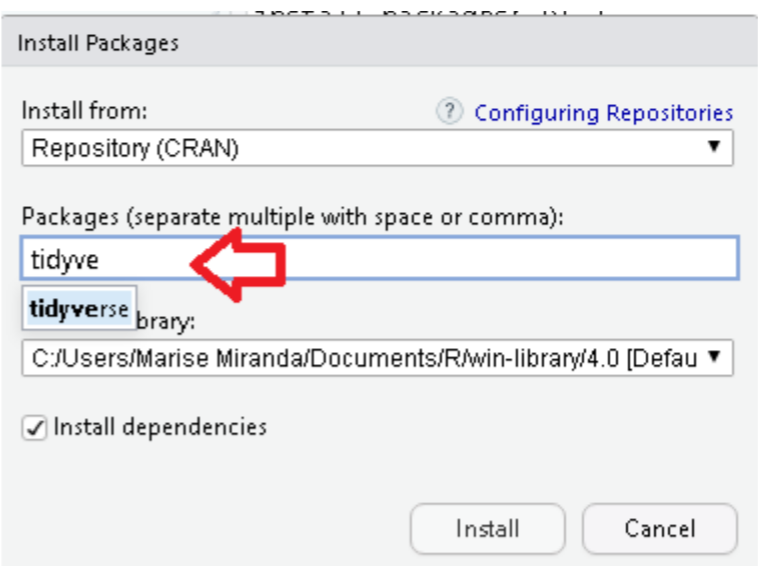

```
library(tidyverse) # trabalha com vários tipos de estruturas de dados
library(ggthemes) # pacotes de temas e escalas aplicados a financeiro
library(corrplot)# pacote gráfico de matrix de correlação
library(GGally)# combina dados de matrix em interações geométricas
library(DT)# matrizes ou data frame que podem ser representados em HTML
library(caret)# simplificação de modelos preditivos
```

Carregue os dados disponíveis para análise. O conjunto de dados é constituído de registros do banco coletado sobre a situação de inadimplência e o perfil dos clientes.

Sugestão: carregue da área de trabalho

```
>loan=read.csv("C:/Users/Marise Miranda/Desktop/loan_data_set.csv",na =" ")
> View(loan)
> colnames(loan)
 [1]"Loan_ID"         "Gender"          "Married"
 [4]"Dependents"      "Education"       "Self_Employed"
[7] "ApplicantIncome"  "CoapplicantIncome" "LoanAmount"
[10] "Loan_Amount_Term" "Credit_History"  "Property_Area"
[13] "Loan_Status"
```

Seleção de recursos para a modelagem:

O conjunto de dados contém informações de idade, renda anual, grau de funcionário, casa própria que afetam a probabilidade de inadimplência do mutuário. As colunas que vamos usar são:

- **Loan_status** : tomou empréstimo? Yes, no
- **LoanAmount**: montante total do empréstimo tomado
- **Self_Employed** : emprego por conta própria
- **Property_Area** : Tipo de propriedade da casa/região
- **ApplicantIncome**: renda
- **CoapplicationIncome:** renda avalista
- **Loan_Amount_Term** : **período de** 36 ou 60 meses

Vamos agora atribuir uma seleção de colunas a uma nova variável, usaremos o select para as colunas da tabela, usando o operador pipe (%>%), para que seja usado o valor resultante da expressão do lado esquerdo como primeiro argumento da função do lado direito.

PARTE 4 – Análise Crédito - Modelagem

Para ter acesso ao pipe use o package: install.packages("magrittr")

```
>loanteste1 = loan %>%
+          select(Loan_Status, LoanAmount, Credit_History, Gender, ApplicantIncome, Loan_Am
ount_Term)


>loanteste1
Loan_Status LoanAmount Credit_History Gender ApplicantIncome Loan_Amount_Term
1     Y     NA     1  Male     5849     360
2     N     128    1  Male     4583     360
3     Y     66     1  Male     3000     360
4     Y     120    1  Male     2583     360
5     Y     141    1  Male     6000     360
6     Y     267    1  Male     5417     360
7     Y     95     1  Male     2333     360
8     N     158    0  Male     3036     360
9     Y     168    1  Male     4006     360
10    N     349    1  Male     12841    360
11    Y     70     1  Male     3200     360
12    Y     109    1  Male     2500     360
13    Y     200    1  Male     3073     360
14    N     114    1  Male     1853     360
15    Y     17     1  Male     1299     120
16    Y     125    1  Male     4950     360
17    Y     100    NA Male     3596     240
18    N     76     0 Female    3510     360
19    N     133    1  Male     4887     360
20    Y     115    1  Male     2600     NA
21    N     104    0  Male     7660     360
22    Y     315    1  Male     5955     360
23    N     116    0  Male     2600     360
24    N     112    0  <NA>     3365     360
……
```

Vamos verificar quantos NA temos em nossa base de dados:

```
> sapply(loanteste1 , function(x) sum(is.na(x)))
Loan_Status    LoanAmount  Credit_History    Gender ApplicantIncome Loan_Amount_Te
rm
          0    22          50          0          0          14
```

Vamos retirar esses valores ausentes:

Msc Eduardo Verri
Dra Marise Miranda


```
> loanteste2 = loanteste1 %>%
+              filter(!is.na(Loan_Amount_Term),
+              !is.na(LoanAmount),
+                !is.na(Credit_History))

> loanteste2
   Loan_Status LoanAmount Credit_History Gender ApplicantIncome Loan_Amount_Term
1          N       128           1  Male          4583           360
2          Y        66           1  Male          3000           360
3          Y       120           1  Male          2583           360
4          Y       141           1  Male          6000           360
5          Y       267           1  Male          5417           360
6          Y        95           1  Male          2333           360
7          N       158           0  Male          3036           360
8          Y       168           1  Male          4006           360
9          N       349           1  Male         12841           360
10         Y        70           1  Male          3200           360
11         Y       109           1  Male          2500           360
12         Y       200           1  Male          3073           360
13         N       114           1  Male          1853           360
14         Y        17           1  Male          1299           120
```

Outra maneira de retirar os Nas:

```
> loan1<-na.omit(loan)
> loan1

> loan1
   Loan_ID Gender Married Dependents     Education Self_Employed
2  LP001003   Male     Yes          1      Graduate            No
3  LP001005   Male     Yes          0      Graduate           Yes
4  LP001006   Male     Yes          0  Not Graduate            No
5  LP001008   Male      No          0      Graduate            No
6  LP001011   Male     Yes          2      Graduate           Yes
7  LP001013   Male     Yes          0  Not Graduate            No
8  LP001014   Male     Yes         3+      Graduate            No
9  LP001018   Male     Yes          2      Graduate            No
10 LP001020   Male     Yes          1      Graduate            No
11 LP001024   Male     Yes          2      Graduate            No
12 LP001027   Male     Yes          2      Graduate
13 LP001028   Male     Yes          2      Graduate            No
14 LP001029   Male      No          0      Graduate            No
15 LP001030   Male     Yes          2      Graduate            No
```

```
> sapply(loan1 , function(x) sum(is.na(x)))
      Loan_ID            Gender        Married       Dependents
            0                 0              0                0
    Education     Self_Employed  ApplicantIncome CoapplicantIncome
            0                 0              0                0
   LoanAmount Loan_Amount_Term  Credit_History   Property_Area
            0                 0              0                0
  Loan_Status
            0
```

Análise Exploratória dos dados:

empréstimo_status :

```
> loanteste2 %>%
+       count(Loan_Status) %>%
+       ggplot(aes(x = reorder(Loan_Status , desc(n)), y = n , fill = n )) +
+       geom_col() +
+       coord_flip() +
+       labs(x = 'Status Empréstimo', y = 'Count')
```

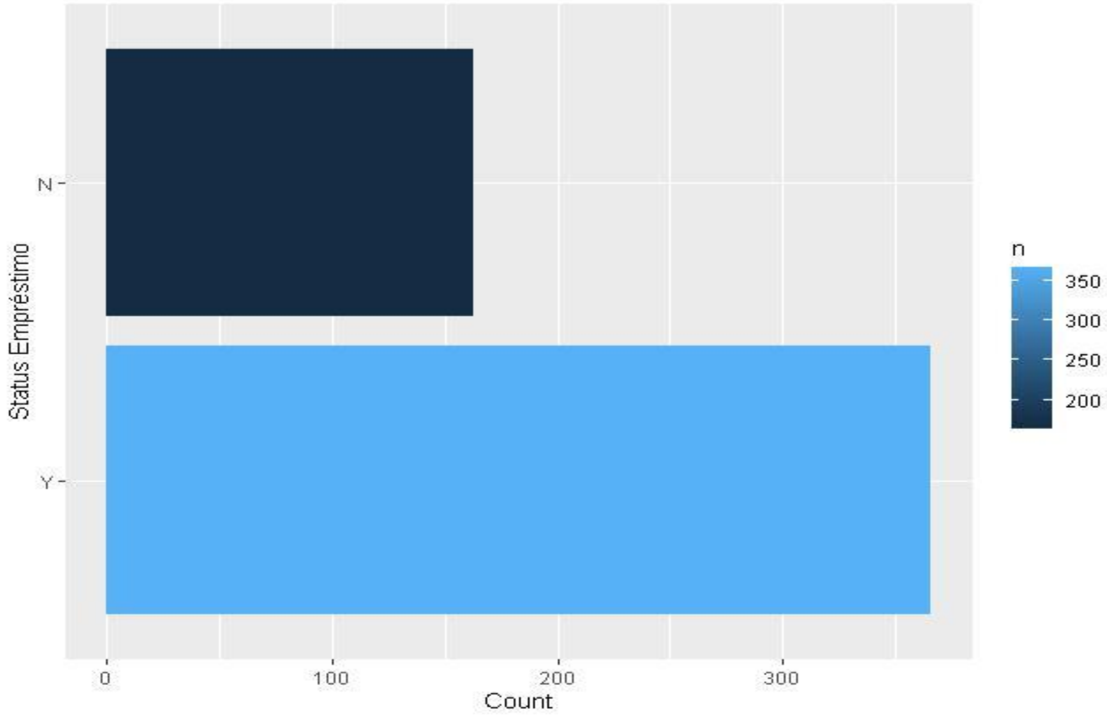

Análises de concessão de crédito:

Renda do Requerente do empréstimo e graduação

Vamos observar como essas variáveis podem ser úteis para a modelagem de risco de crédito. Sabe-se que quanto melhor a nota, menor a taxa de juros. Podemos visualizar isso perfeitamente com boxplots.

```
ggplot(loan, aes(x = Education, y = ApplicantIncome, fill = Education)) +
+    geom_boxplot() +
+    theme_gray()+
+ labs(y='Renda Requerente', x= 'Graduação')
```

PARTE 4 – Análise Crédito - Modelagem

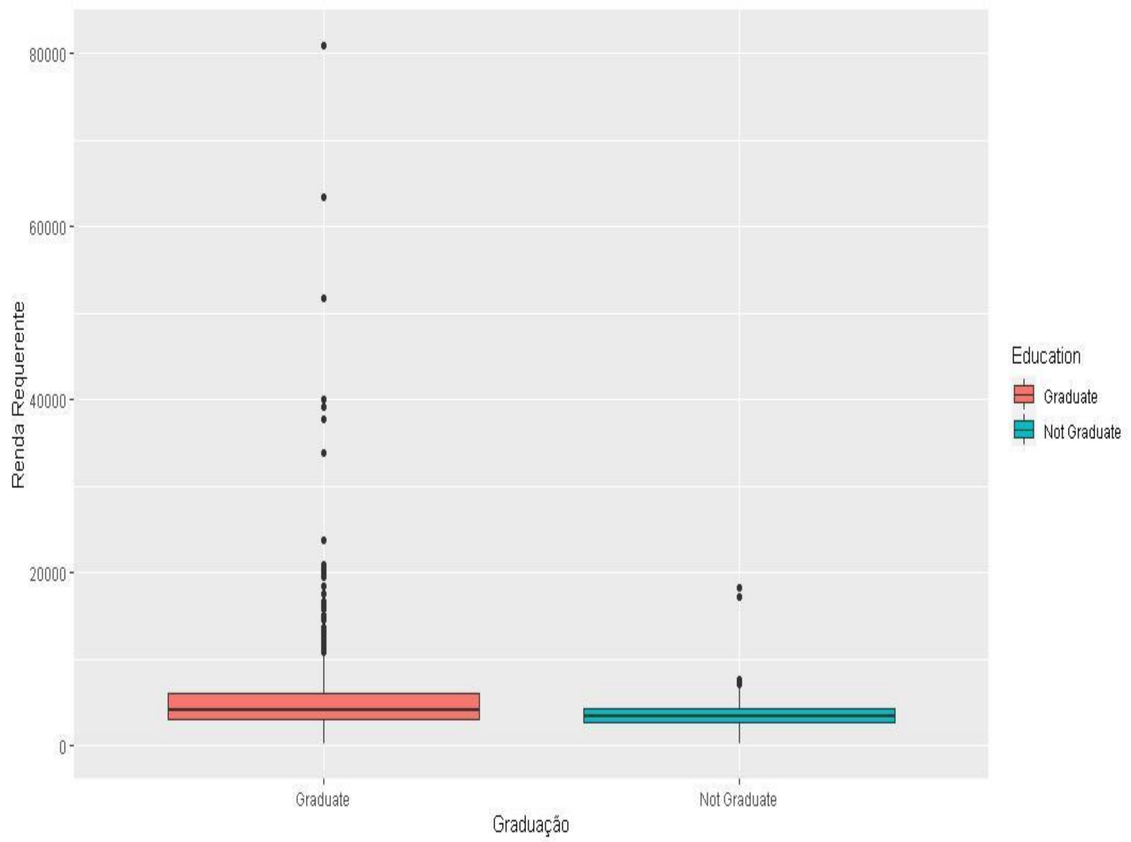

Assumimos que o grau de escolaridade é um grande indicador do volume de empréstimos Mas quantas delas não tiveram desempenho agrupado por série?

A decisão da análise requer a formação de subsets, que levem em consideração a tomada de empréstimos e ou o nível de graduação.

Perceba que no gráfico de renda do requerente pelo nível de estudo tem outliers.

Vamos limpar esses outliers.

```
> loanteste3 = loan %>%

+       select(Loan_Status, LoanAmount,Credit_History,
Gender, ApplicantIncome,Loan_Amount_Term, Education)


> loanteste3
   Loan_Status LoanAmount Credit_History Gender ApplicantIncome
Loan_Amount_Term   Education
1           Y         NA              1   Male            5849             360     Graduate
2           N        128              1   Male            4583             360     Graduate
3           Y         66              1   Male            3000             360     Graduate
4           Y        120              1   Male            2583             360 Not Graduate
5           Y        141              1   Male            6000             360     Graduate
6           Y        267              1   Male            5417             360     Graduate
```

Vamos retirar os NAs

```
> loansubset1
   Loan_Status LoanAmount Credit_History Gender ApplicantIncome
Loan_Amount_Term  Education
2          N      128          1  Male        4583          360     Graduate
3          Y       66          1 Male         3000          360     Graduate
4          Y      120          1  Male        2583          360 Not Graduate
5          Y      141          1  Male        6000          360     Graduate
6          Y      267          1  Male        5417          360     Graduate
7          Y       95          1 Male         2333          360 Not Graduate
8          N      158          0  Male        3036          360     Graduate
9          Y      168          1  Male        4006          360     Graduate
10         N      349          1  Male       12841          360     Graduate
11         Y       70          1  Male        3200          360     Graduate
12         Y      109          1  Male        2500          360     Graduate
```

```
> loansubset1<-na.omit(loanteste3)
```

```
> loansubset1
   Loan_Status      LoanAmount      Credit_History      Gender      ApplicantIncome
Loan_Amount_Term  Education
2          N      128          1  Male        4583          360     Graduate
3          Y       66          1  Male        3000          360     Graduate
4          Y      120          1  Male        2583          360 Not Graduate
5          Y      141          1  Male        6000          360     Graduate
6          Y      267          1  Male        5417          360     Graduate
7          Y       95          1  Male        2333          360 Not Graduate
8          N      158          0  Male        3036          360     Graduate
9          Y      168          1  Male        4006          360     Graduate
10         N      349          1  Male       12841          360     Graduate
11         Y       70          1  Male        3200          360     Graduate
12         Y      109          1  Male        2500          360     Graduate
13         Y      200          1  Male        3073          360     Graduate
14         N      114          1  Male        1853          360     Graduate
15         Y       17          1  Male        1299          120     Graduate
16         Y      125          1  Male        4950          360     Graduate
18         N       76          0 Female       3510          360     Graduate
19         N      133          1  Male        4887          360 Not Graduate
21         N      104          0  Male        7660          360 Not Graduate
22         Y      315          1  Male        5955          360     Graduate
```

```
>summary(loansubset1)
```

PARTE 4 – Análise Crédito - Modelagem

```
Loan_Status         LoanAmount     Credit_History     Gender          ApplicantIncome Loan_Amount_Term  Education
Length:529         Min.   :  9.0   Min.   :0.0000   Length:529         Min.   :  150   Min.   : 36.0   Length:529
Class :character   1st Qu.:100.0   1st Qu.:1.0000   Class :character   1st Qu.: 2900   1st Qu.:360.0   Class :character
Mode  :character   Median :128.0   Median :1.0000   Mode  :character   Median : 3816   Median :360.0   Mode  :character
                   Mean   :145.9   Mean   :0.8507                      Mean   : 5508   Mean   :342.4
                   3rd Qu.:167.0   3rd Qu.:1.0000                      3rd Qu.: 5815   3rd Qu.:360.0
                   Max.   :700.0   Max.   :1.0000                      Max.   :81000   Max.   :480.0
```

Vamos localizar os valores outliers para remoção. Observando o valor máximo de 81000 em ApplicantIncome.

```
> loansubset2<-loansubset1[loansubset1$ApplicantIncome>80000,]
> loansubset2
```

```
  410          N          360            0  Male
    ApplicantIncome Loan_Amount_Term Education
  410          81000               360  Graduate
```

O subset loansubset2 mostra as linhas com valores acima de 80000, para localizar a linha a ser removida.

Vamos fazer um subset novo a partir da remoção da linha encontrada com o outlier. No entando precisamos incluir uma coluna de ID.

```
> summary(loansubset1
+ )
 Loan_Status          LoanAmount    Credit_History
 Length:529         Min.   :  9.0   Min.   :0.0000
 Class :character   1st Qu.:100.0   1st Qu.:1.0000
 Mode  :character   Median :128.0   Median :1.0000
                    Mean   :145.9   Mean   :0.8507
                    3rd Qu.:167.0   3rd Qu.:1.0000
                    Max.   :700.0   Max.   :1.0000
    Gender          ApplicantIncome Loan_Amount_Term
 Length:529         Min.   :  150   Min.   : 36.0
 Class :character   1st Qu.: 2900   1st Qu.:360.0
 Mode  :character   Median : 3816   Median :360.0
                    Mean   : 5508   Mean   :342.4
                    3rd Qu.: 5815   3rd Qu.:360.0
                    Max.   :81000   Max.   :480.0
  Education
 Length:529
 Class :character
 Mode  :character
```

> loansubset1$id<-c(1:529)

> loansubset1

Veja que uma coluna de id foi criada

> loansubset2<-loansubset1[loansubset1$ApplicantIncome>80000,]

> loansubset2

```
    Loan_Status LoanAmount Credit_History Gender
410           N        360              0   Male
    ApplicantIncome Loan_Amount_Term Education id
410           81000              360  Graduate 352
```

E o id que porcuramos relativo ao outlier 81000 é o 352.

Vamos remover agora:

> loanremove<-loansubset1[-352,]

> summary(loanremove)

```
 Loan_Status          LoanAmount    Credit_History      Gender          ApplicantIncome Loan_Amount_Term  Education              id       
 Length:528         Min.   :  9.0   Min.   :0.0000   Length:528         Min.   :  150   Min.   : 36.0    Length:528         Min.   :  1.0  
 Class :character   1st Qu.:100.0   1st Qu.:1.0000   Class :character   1st Qu.: 2899   1st Qu.:360.0    Class :character   1st Qu.:132.8  
 Mode  :character   Median :128.0   Median :1.0000   Mode  :character   Median : 3815   Median :360.0    Mode  :character   Median :264.5  
                    Mean   :145.4   Mean   :0.8523                      Mean   : 5365   Mean   :342.3                       Mean   :264.8  
                    3rd Qu.:166.2   3rd Qu.:1.0000                      3rd Qu.: 5804   3rd Qu.:360.0                       3rd Qu.:397.2  
                    Max.   :700.0   Max.   :1.0000                      Max.   :63337   Max.   :480.0                       Max.   :529.0  
```

O máximo valor de ApplicantIncome é 63337. Vamos ver como ficam o boxplot.

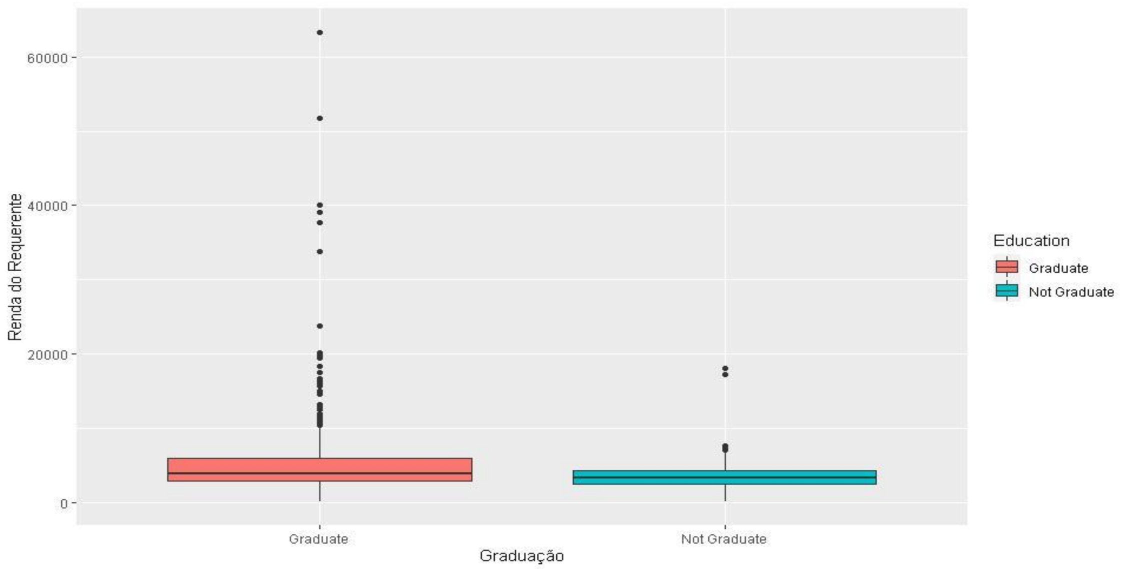

Msc Eduardo Verri
Dra Marise Miranda

Vamos continuar nossa análise exploratória.

Não melhorou muito a análise de concessão de crédito. Vamos ajustar um novo subset desta vez removendo os outliers acima de 40000, mas vamos verificar qunatos teremos que remover.

```
> loansubset2<-loansubset1[loansubset1$ApplicantIncome>40000,]
> loansubset2
```

```
 172      Y      700       1
 334      Y      490       1  Male
 410      N      360       0  Male

 172      51763      300 Graduate 144
 334      63337      180 Graduate 285
 410      81000      360 Graduate 352
```

Vamos remover os três id, lembre-se que não removemos da base original já tratada criamos outro subset de remoção

```
> loanremove1<-loansubset1[-352,]

> loanremove2<-loanremove1[-285,]

> loanremove3<-loanremove2[-144,]

> loanremove3
```

```
> summary(loanremove3)

 Loan_Status         LoanAmount    Credit_History
 Length:526         Min.   : 9.0   Min.   :0.0000
 Class :character   1st Qu.:100.0  1st Qu.:1.0000
 Mode  :character   Median :128.0  Median :1.0000
                    Mean   :143.7  Mean   :0.8517
                    3rd Qu.:165.0  3rd Qu.:1.0000
                    Max.   :600.0  Max.   :1.0000
    Gender          ApplicantIncome Loan_Amount_Term
 Length:526         Min.   : 150   Min.   : 36.0
 Class :character   1st Qu.: 2896  1st Qu.:360.0
 Mode  :character   Median : 3814  Median :360.0
                    Mean   : 5166  Mean   :342.7
                    3rd Qu.: 5766  3rd Qu.:360.0
                    Max.   :39999  Max.   :480.0
  Education              id
 Length:526         Min.   :  1.0
 Class :character   1st Qu.:132.2
```

```
 Mode :character   Median :264.5
                   Mean   :265.0
                   3rd Qu.:397.8
                   Max.   :529.0
```

Veja que foram removidos apenas três dados ficando com 526 observações.

Vamos novamente gerar o boxplot, mas desta vez com o novo subset loanremove3.

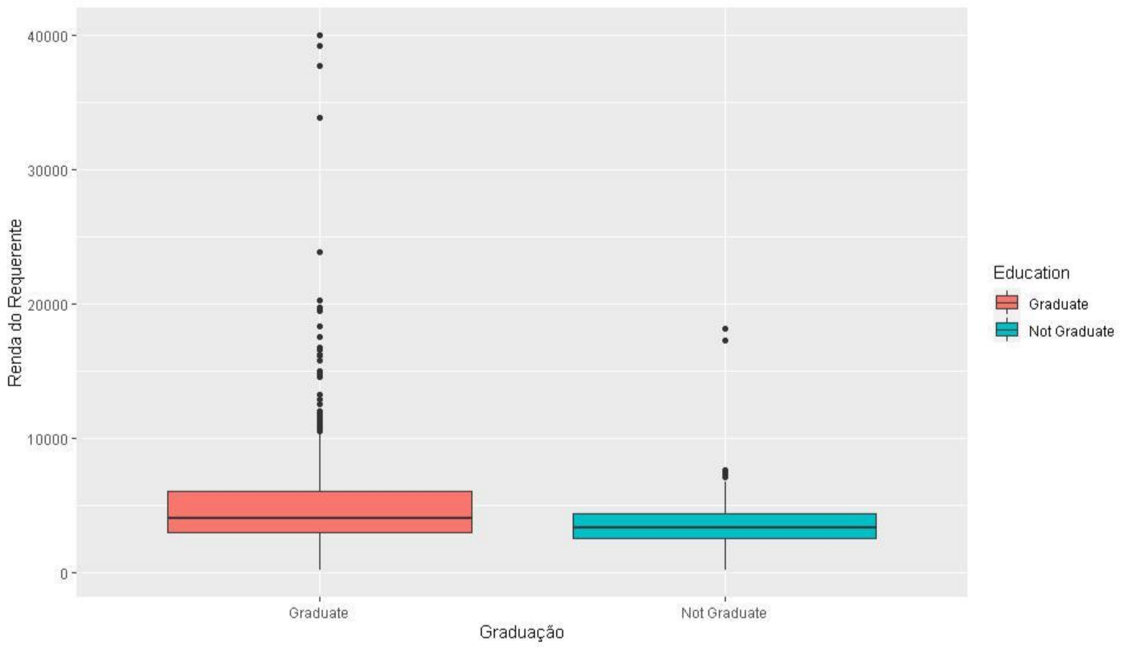

Podemos melhorar mais ainda, removendo os ouliers que afetam este conjunto de análise. Mas vcs podem fazer isso depois. Agora vamos analisar o gráfico boxplot.

Ele tenta nos mostrar a distribuição dos dados, com o valor mínimo, 1º quartil, média, mediana, 3º quartil, máximo.

Até que tenhamos uma boa situação de análise para que possamos ser acertivos na concessão de crédito a mais pessoas de interesse.

E assim vamos criando novos data sets a partir do original, fazendo melhorias e diminuindo os outliers de modo a ter um cluster mais estável para tomada de decisão que possa atender um nicho muito característico.

Vamos trabalhar com um modelo de Regressão Logística:

No R instale em tools Install Packages:
Amelia

Na console digite:

PARTE 4 – Análise Crédito - Modelagem

```
>library(Amelia)
> missmap(loanremove3,main = "valores ausentes")
```

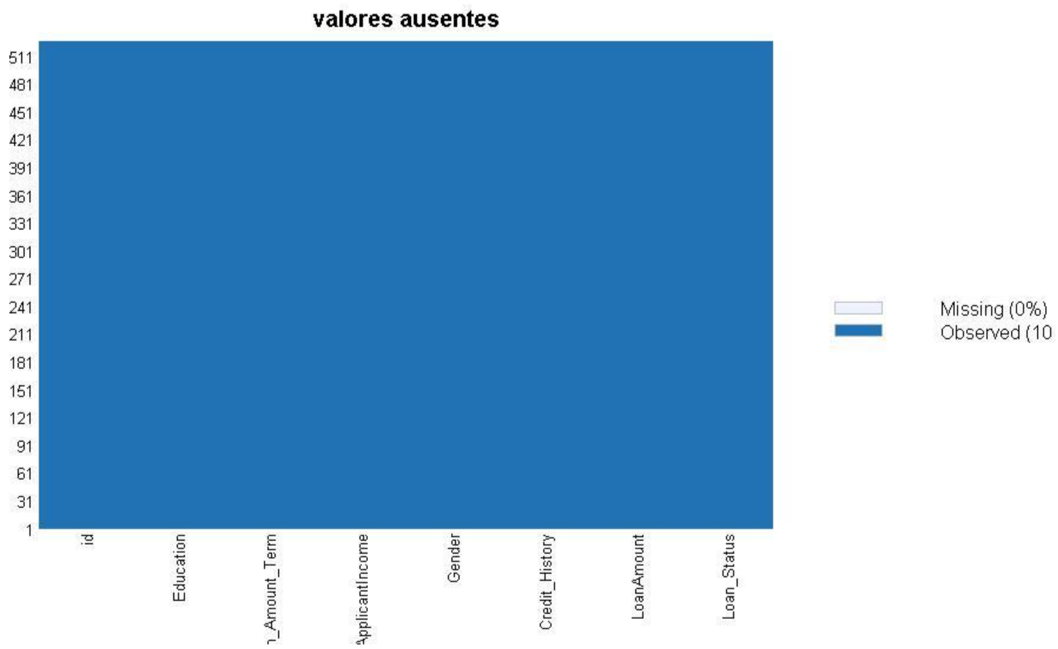

Verificamos que não temos valores ausentes no dataset loanremove3.

Modelos lineares generalizados: Como um lembrete, os Modelos Lineares Generalizados são uma extensão dos modelos de regressão linear que permitem que a variável dependente seja não normal.

A regressão logística é amplamente utilizada dentre os modelos generalizados. A regressão logística é usada para prever uma classe, ou seja, uma probabilidade. A regressão logística pode prever um resultado binário com precisão.

Imagine que você deseja prever se um empréstimo será negado / aceito com base em muitos atributos. A regressão logística é da forma 0/1. y = 0 se um empréstimo for rejeitado, y = 1 se aceito.

Um modelo de regressão logística difere do modelo de regressão linear de duas maneiras.

- Em primeiro lugar, a regressão logística aceita apenas entrada dicotômica (binária) como variável dependente (ou seja, um vetor de 0 e 1).
- Em segundo lugar, o resultado é medido pela seguinte função de ligação probabilística chamada **sigmóide** devido à sua forma de S:

$$\textbf{\textit{Prlog}} = \frac{1}{1 + e^{-(b_0 + b_1 X_1 + b_2 X_2 + \cdots + b_k X_k)}}$$

Msc Eduardo Verri
Dra Marise Miranda

Aqui é possível perceber que quanto mais elementos de análise são incluidos nas variáveis idependentes mais chances de sucesso são possíveis.

A saída da função está sempre entre 0 e 1. Verifique a imagem abaixo

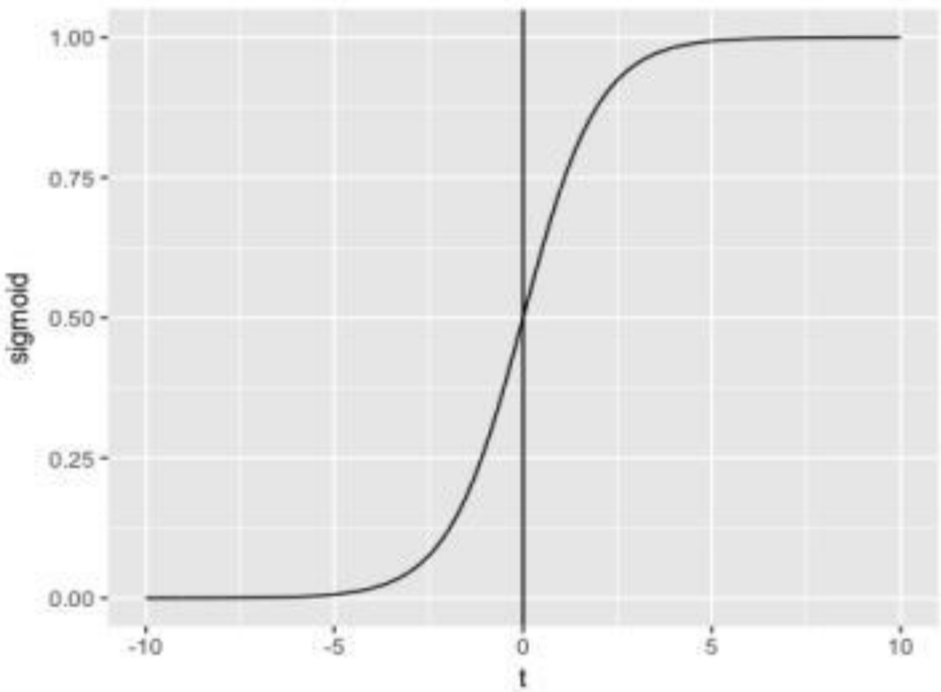

Observe melhor e compare a um modelo de distribuição binominal parcial, aproximada de uma normal.

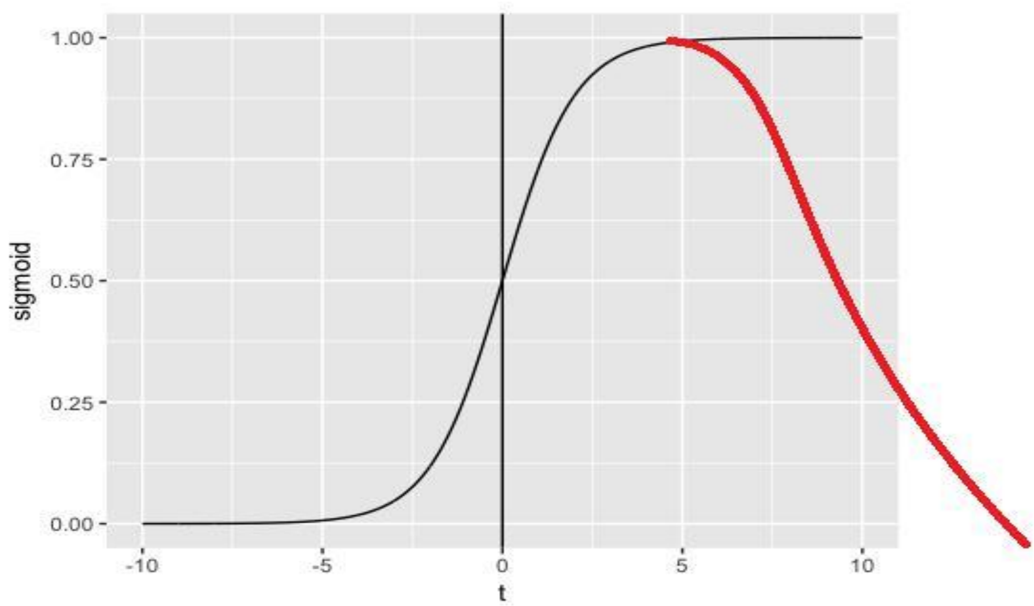

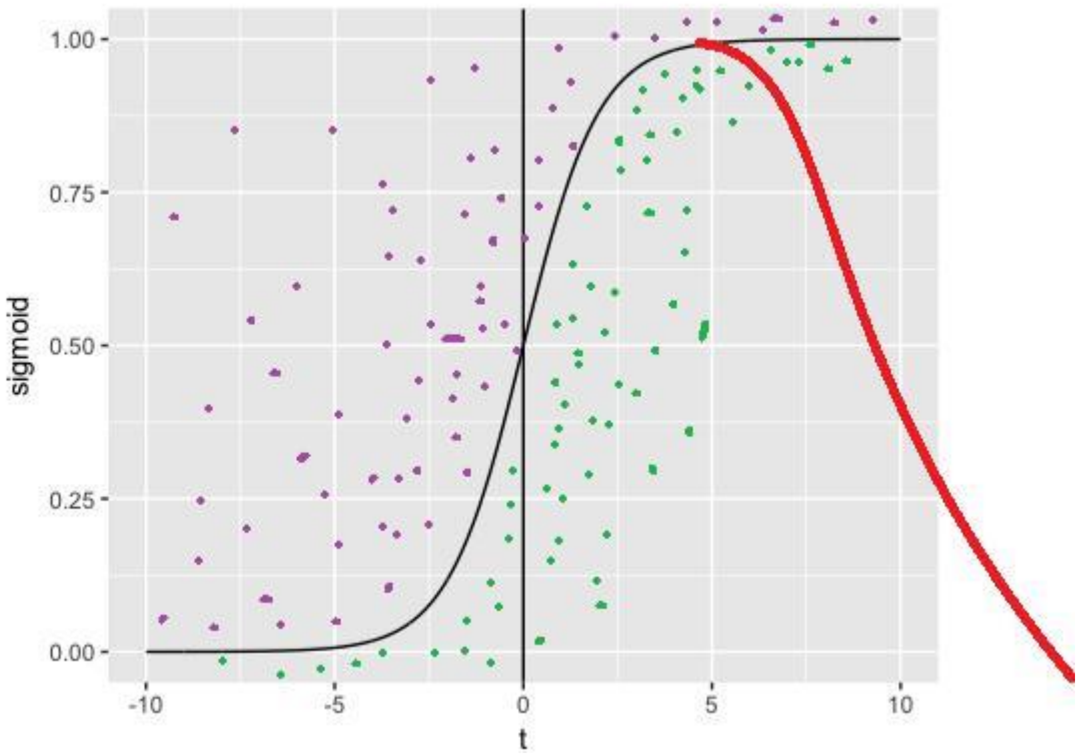

Por este motivo devemos usar um modelo generalizado.

Devemos considerar os GLMs principalmente quando a variável resposta é expressa em:

- contagens simples
- contagem expressa em proporções
- número de sucesso e tentativa
- variáveis binárias (ex. morto x vivo)
- tempo para o evento ocorrer (modelos de sobrevivência)

Os modelos lineares generalizados (**GLMs**) são uma ampliação dos modelos lineares. Os **GLM's** são usados quando os resíduos (erro) do modelo apresentam distribuição diferente da normal (gaussiana). Por exemplos, variáveis de contagem são inteiras e apresentam os valores limitados no zero. Esse tipo de variável, em geral, tem uma distribuição de erros assimétrica para valores baixos e uma variância que aumenta com a média dos valores preditos, violando duas premissas dos modelos lineares.

Funções de ligações canônicas

Para alguns tipos de famílias de variáveis temos funções de ligações padrões. As mais usadas são:

Natureza da resposta	Estrutura dos resíduos (erro)	Função de ligação
contínua	normal	identidade
contagem	poisson	log
proporção	binomial	logit

Só pra lembrar a forma canônica é a forma matemática mais simples que explica o modelo ou método. Em linguagem léxica, canônica é a junção de uma sílaba com uma vogal (mato= ma – to)

Em linguagem R temos as funções implícitas dentro do Package GLM – Modelos lineares generalizados. Sendo o objeto da classe "family" que contém os modelos das distribuições dos erros e o link da função a ser usado no modelo. Conforme tabela abaixo. Apenas assimile.

family(object, …)

binomial(link = "logit") → eventos binários (fumante ou não fumante) gaussian(link = "identity") → medidas físicas (peças x defeitos) Gamma(link = "inverse") → tempo de vida de produto inverse.gaussian(link = "1/mu^2") → lançamento de um novo produto poisson(link = "log") → eventos imprevisíveis (sentenças criminais) quasi(link = "identity", variance = "constant") → cadeia produtiva x produção quasibinomial(link = "logit") → usado como parâmetro extra quasipoisson(link = "log") → usado como parâmetro extra

Aplicar a Regressão logistica.

A regressão logística é útil quando você está prevendo um resultado binário de um conjunto de variáveis preditoras contínuas. É frequentemente preferível à análise de função discriminante por causa de suas suposições menos restritivas.

Para ajustar um modelo usando a função glm você precisa passar a fórmula do modelo, a família da distribuição que você quer ajustar (por exemplo, binomial para dados binários, poisson para dados de contagem, gaussian para o modelo linear tradicional e assim por diante) juntamente com o link (por exemplo, probit, logit para binomial). Se você não especificar o link o R vai usar o default para a distribuição escolhida.

Então para começar, você tem que ter uma ideia de qual (quais) modelo(s) você quer ajustar e seguir mais ou menos as ideias esboçadas acima. No seu caso, sua fórmula seria algo como **DesempenhoTécnico ~ % comunicação + % empatia + % resiliência + %gestão tempo + % relacionamento + % iniciativa + % flexibilidade** + etc ou outra forma funcional mais adequada.

Porém, explicar qual a forma funcional que você tem que adotar, ou qual a distribuição ou link que você tem que escolher é algo específico que envolve cálculo/dados e conhecimento substantivo do problema/contexto.

Regressão de Poisson

A regressão de Poisson é útil ao prever uma variável de resultado que representa contagens de um conjunto de variáveis preditoras contínuas. Exemplo: contagem de dados e tabelas de contigência.

Tabelas de contigência: inclinação partidária por gênero. Veja a tabela abaixo com os totalizadores, mas em que momento há uma proporção maior, em cada parte?

Inclinação Partidária			
Gênero	Democratas	Republicanos	Total
Feminino	883	477	1360
Masculino	352	458	810
Total	1235	935	2170

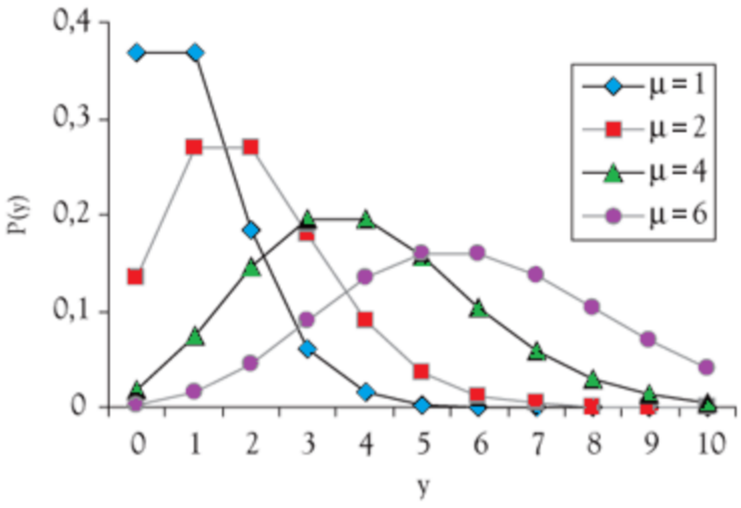

Exemplo autoral

Análise de Sobrevivência

As técnicas estatísticas conhecidas como análise de sobrevida são utilizadas quando se pretende analisar um fenômeno em relação a um período de tempo, isto é, ao tempo transcorrido entre um evento inicial, no qual um sujeito ou um objeto entra em um estado particular e um evento final, que modifica este estado. Assim, descrevem não só, como sugerido por seu nome, se os pacientes vivem ou morrem, mas também outros desfechos dicotômicos tais como recaída da doença, desmame do lactente etc.

A análise de sobrevivência (também chamada de análise de histórico de eventos ou análise de confiabilidade) abrange um conjunto de técnicas para modelar o tempo até um evento. Os dados podem ser censurados corretamente - o evento pode não ter ocorrido no final do estudo ou podemos ter informações incompletas sobre uma observação, mas sabemos que até um determinado momento o evento não havia ocorrido (por exemplo, o participante foi excluido do estudo, mas estava vivo naquela época).

Vamos voltar ao nosso estudo de caso de crédito financeiro e aplicar a regressão logística:

```
> glm(loanremove3$Credit_History ~loanremove3$Gender, family = binomial(link = logit))

Call: glm(formula = loanremove3$Credit_History ~ loanremove3$Gender,
    family = binomial(link = logit))

Coefficients:
         (Intercept) loanremove3$GenderFemale    loanremove3$GenderMale
            0.9808               0.6931               0.8109

Degrees of Freedom: 525 Total (i.e. Null); 523 Residual
Null Deviance:      441.6
Residual Deviance: 440.3         AIC: 446.3
```

```
> glm(loanremove3$Credit_History ~loanremove3$Gender + loanremove3$Education, family = binomial(link = logit))

Call: glm(formula = loanremove3$Credit_History ~ loanremove3$Gender +
    loanremove3$Education, family = binomial(link = logit))

Coefficients:
                 (Intercept)          loanremove3$GenderFemale           loanremove3$GenderMale
loanremove3$EducationNot Graduate
                      1.0253                     0.7292                0.8778                  -0.4501

Degrees of Freedom: 525 Total (i.e. Null); 522 Residual
Null Deviance:    441.6
Residual Deviance: 437.9          AIC: 445.9
```

Msc Eduardo Verri
Dra Marise Miranda

> glm(loanremove3$Credit_History ~loanremove3$Gender + loanremove3$Education + loanremove3$ApplicantIncome, family = binomial(link = logit))

Call: glm(formula = loanremove3$Credit_History ~ loanremove3$Gender +
loanremove3$Education + loanremove3$ApplicantIncome, family = binomial(link = logit))

Coefficients:
(Intercept) loanremove3$GenderFemale loanremove3$GenderMale
loanremove3$EducationNot Graduate
9.348e-01 7.563e-01 9.009e-01 -4.307e-01 loanremove3$ApplicantIncome

1.242e-05

Degrees of Freedom: 525 Total (i.e. Null); 521 Residual
Null Deviance: 441.6
Residual Deviance: 437.7 AIC: 447.7